

# サポートベクタマシン Support Vector Machine



## SVM

= マージン最大化 + カーネルトリック

### □ 線形モデル


- 線形分離可能な問題の定式化
- 線形分離不可能な問題の定式化

### □ 非線形モデル

- 次元拡張
- カーネルトリック



# マージン最大化



次の学習データが与えられたとする。


$$(y_1, \mathbf{x}_1), (y_2, \mathbf{x}_2), \dots, (y_m, \mathbf{x}_m), \quad \mathbf{x} \in R^n, y \in \{-1, 1\}$$

ただし,

$$y = \begin{cases} 1 & \dots & \text{Class I} \\ -1 & \dots & \text{Class II} \end{cases}$$



# マージン最大化




カテゴリ I とカテゴリ II は、以下の超平面で分離可能であったとする。

$$\varphi^T \cdot x = c, \quad \|\varphi\| = 1$$



# マージン最大化




ここで,

$$\begin{aligned} \boldsymbol{\varphi}^T \cdot \boldsymbol{x}_i &> c, & \text{if } \boldsymbol{x}_i \in \text{Class I} \\ \boldsymbol{\varphi}^T \cdot \boldsymbol{x}_i &< c, & \text{if } \boldsymbol{x}_i \in \text{Class II} \end{aligned}$$



# マージン最大化




以下のように $c_1, c_2$ を定義する。

$$c_1(\varphi) = \min_{x_i \in I} \varphi^T \cdot x_i, c_2(\varphi) = \max_{x_i \in II} \varphi^T \cdot x_i.$$

$\rho = (c_1 - c_2)/2$  を“マージン”と呼ぶ。



# マージン最大化




異なる  $\varphi$  に対し, 異なる  $c_1, c_2$  が定まる。

$$c_1(\varphi) = \min_{x_i \in I} \varphi^T \cdot x_i$$

$$c_2(\varphi) = \max_{x_i \in II} \varphi^T \cdot x_i$$



# マージン最大化



異なる  $\phi$  に対し, 異なる  $c_1, c_2$  が定まる。


$$c_1(\phi) = \min_{x_i \in I} \phi^T \cdot x_i$$

$$c_2(\phi) = \max_{x_i \in II} \phi^T \cdot x_i$$





# マージン最大化




マージンを最大化する  $\varphi_0$  を考える。

$$\varphi_0 = \operatorname{argmax}_{\varphi} \rho(\varphi) = \operatorname{argmax}_{\varphi} \frac{c_1(\varphi) - c_2(\varphi)}{2}$$



# マージン最大化



このとき、次式は 最も危険の少ない識別境界となる。

$$\varphi_0^T \cdot \mathbf{x} = c_0, \quad \|\varphi_0\| = 1$$

ここで、

$$c_0 = \frac{c_1(\varphi_0) + c_2(\varphi_0)}{2}$$



# SVMの問題

$$\boldsymbol{\varphi}_0 = \operatorname{argmax}_{\boldsymbol{\varphi}} \rho(\boldsymbol{\varphi}) = \operatorname{argmax}_{\boldsymbol{\varphi}} \frac{c_1(\boldsymbol{\varphi}) - c_2(\boldsymbol{\varphi})}{2}. \quad (1)$$

s.t.

$$\begin{aligned} \boldsymbol{\varphi}^T \cdot \boldsymbol{x}_i - c &\geq \rho, & \text{if } y_i = 1 \\ \boldsymbol{\varphi}^T \cdot \boldsymbol{x}_i - c &\leq -\rho, & \text{if } y_i = -1 \end{aligned} \quad (2)$$

ここで,

$$\begin{aligned} \|\boldsymbol{\varphi}\| &= 1, \\ c_1(\boldsymbol{\varphi}) &= \min_{\boldsymbol{x}_i \in I} \boldsymbol{\varphi}^T \cdot \boldsymbol{x}_i, & c_2(\boldsymbol{\varphi}) &= \max_{\boldsymbol{x}_i \in II} \boldsymbol{\varphi}^T \cdot \boldsymbol{x}_i, \\ c &= \frac{c_1(\boldsymbol{\varphi}) + c_2(\boldsymbol{\varphi})}{2} \end{aligned} \quad (3)$$



# 等価な問題

$$\max_{\boldsymbol{\varphi}} \rho(\boldsymbol{\varphi}) = \max_{\boldsymbol{\varphi}} \frac{c_1(\boldsymbol{\varphi}) - c_2(\boldsymbol{\varphi})}{2} \quad \|\boldsymbol{\varphi}\| = 1$$

s. t.

$$\begin{aligned} \boldsymbol{\varphi}^T \cdot \mathbf{x}_i - c &\geq \rho, & \text{if } y_i = 1 \\ \boldsymbol{\varphi}^T \cdot \mathbf{x}_i - c &\leq -\rho, & \text{if } y_i = -1 \end{aligned} \quad c = \frac{c_1(\boldsymbol{\varphi}) + c_2(\boldsymbol{\varphi})}{2}$$



$$\max_{\boldsymbol{\psi}} \rho\left(\frac{\boldsymbol{\psi}}{\|\boldsymbol{\psi}\|}\right) = \max_{\boldsymbol{\psi}} \frac{\rho'(\boldsymbol{\psi})}{\|\boldsymbol{\psi}\|}$$

s. t.

$$\begin{aligned} \boldsymbol{\psi}^T \cdot \mathbf{x}_i - b &\geq \rho'(\boldsymbol{\psi}), & \text{if } y_i = 1 \\ \boldsymbol{\psi}^T \cdot \mathbf{x}_i - b &\leq -\rho'(\boldsymbol{\psi}), & \text{if } y_i = -1 \end{aligned}$$

$$\begin{aligned} \leftarrow \boldsymbol{\varphi} &= \frac{\boldsymbol{\psi}}{\|\boldsymbol{\psi}\|}, \\ \rho\left(\frac{\boldsymbol{\psi}}{\|\boldsymbol{\psi}\|}\right) &= \frac{\rho'(\boldsymbol{\psi})}{\|\boldsymbol{\psi}\|}, \\ b &= c \cdot \|\boldsymbol{\psi}\| \end{aligned}$$



$$\max_{\psi} \rho \left( \frac{\psi}{\|\psi\|} \right) = \max_{\psi} \frac{\rho'(\psi)}{\|\psi\|}$$

s. t.

$$\psi^T \cdot x_i - b \geq \rho'(\psi), \quad \text{if } y_i = 1$$

$$\psi^T \cdot x_i - b \leq -\rho'(\psi), \quad \text{if } y_i = -1$$



$$\min_{\psi} \|\psi\|$$

s. t.

$$\psi^T \cdot x_i - b > 1, \quad \text{if } y_i = 1$$

$$\psi^T \cdot x_i - b < -1, \quad \text{if } y_i = -1$$


$$\begin{aligned} &\leftarrow \max_{\psi} \frac{\rho'(\psi)}{\|\psi\|} \\ &\Leftrightarrow \min_{\psi} \|\psi\|, \rho'(\psi) = 1 \end{aligned}$$

(4)

(5)



# マージン最大化




s. t.

$$\begin{aligned} \varphi^T \cdot x_i - c &\geq \rho(\varphi), & \text{if } y_i = 1 \\ \varphi^T \cdot x_i - c &\leq -\rho(\varphi), & \text{if } y_i = -1 \end{aligned}$$

$$\|\varphi\| = 1$$



# マージン最大化



$$\begin{aligned} s. t. \quad & \psi^T \cdot x_i - b \geq 1, & \text{if } y_i = 1 \\ & \psi^T \cdot x_i - b \leq -1, & \text{if } y_i = -1 \end{aligned}$$



# SVM の問題

$$\boldsymbol{\psi}_0 = \underset{\boldsymbol{\psi}}{\operatorname{argmin}} \|\boldsymbol{\psi}\| \quad (4)$$

s.t.

$$\begin{aligned} \boldsymbol{\psi}^T \cdot \boldsymbol{x}_i - b &> 1, & \text{if } y_i = 1 \\ \boldsymbol{\psi}^T \cdot \boldsymbol{x}_i - b &< -1, & \text{if } y_i = -1 \end{aligned} \quad (5)$$

または,

$$\boldsymbol{\psi}_0 = \underset{\boldsymbol{\psi}}{\operatorname{argmin}} \frac{1}{2} \boldsymbol{\psi}^T \boldsymbol{\psi} \quad (6)$$

s.t.

$$\begin{aligned} \boldsymbol{\psi}^T \cdot \boldsymbol{x}_i - b &> 1, & \text{if } y_i = 1 \\ \boldsymbol{\psi}^T \cdot \boldsymbol{x}_i - b &< -1, & \text{if } y_i = -1 \end{aligned} \quad (5)$$





## ラグランジュ定数 $\alpha$ を導入してラグランジュ関数を定める

目的関数      ラグランジュ定数      制約

$$L(\boldsymbol{\psi}, b, \boldsymbol{\alpha}) = \frac{1}{2} \boldsymbol{\psi}^T \boldsymbol{\psi} - \sum_{i=1}^m \alpha_i (y_i (\boldsymbol{\psi}^T \mathbf{x}_i - b) - 1)$$
$$= \frac{1}{2} \boldsymbol{\psi}^T \boldsymbol{\psi} - \boldsymbol{\alpha}^T D^T \boldsymbol{\psi} + b \boldsymbol{\alpha}^T \mathbf{y} + \|\boldsymbol{\alpha}\|_1 \quad (7)$$

$$D = (y_1 \mathbf{x}_1, y_2 \mathbf{x}_2, \dots, y_m \mathbf{x}_m)$$

双対問題を導くために、設計変数  $\boldsymbol{\psi}, b$  で、 $L(\boldsymbol{\psi}, b, \boldsymbol{\alpha})$  を偏微分

$$\frac{\partial}{\partial \boldsymbol{\psi}} L(\boldsymbol{\psi}, b, \boldsymbol{\alpha}) = \boldsymbol{\psi} - D \boldsymbol{\alpha} = 0$$

$$\frac{\partial}{\partial b} L(\boldsymbol{\psi}, b, \boldsymbol{\alpha}) = \boldsymbol{\alpha}^T \mathbf{y} = 0$$



以下の解を得る。

$$\boldsymbol{\psi} = D\boldsymbol{\alpha}, \quad \boldsymbol{\alpha}^T \mathbf{y} = 0 \quad (8)$$

これらを  $L(\boldsymbol{\psi}, b, \boldsymbol{\alpha})$  に代入

$$\begin{aligned} L(\boldsymbol{\alpha}) &= \frac{1}{2} \boldsymbol{\alpha}^T D^T D \boldsymbol{\alpha} - \boldsymbol{\alpha}^T D^T D \boldsymbol{\alpha} + b \cdot \boldsymbol{\alpha}^T \mathbf{y} + \|\boldsymbol{\alpha}\|_1 \\ &= -\frac{1}{2} \boldsymbol{\alpha}^T D^T D \boldsymbol{\alpha} + \|\boldsymbol{\alpha}\|_1 \\ &= -\frac{1}{2} \boldsymbol{\alpha}^T A \boldsymbol{\alpha} + \|\boldsymbol{\alpha}\|_1 \end{aligned} \quad (9)$$

$$A = \left( (y_i \mathbf{x}_i)^T (y_j \mathbf{x}_j) \right) = (y_i y_j \mathbf{x}_i^T \mathbf{x}_j)$$



双対問題は以下のとおりとなる。

$$\alpha^0 = \max_{\alpha} L(\alpha) = \max_{\alpha} \left( -\frac{1}{2} \alpha^T A \alpha + \|\alpha\|_1 \right) \quad (10)$$

$$\text{s.t.} \quad A = (y_i y_j \mathbf{x}_i^T \mathbf{x}_j)$$

$$\alpha_i \geq 0, \quad i = 1, 2, \dots, m \quad (11)$$

$\alpha^0$  を用いて、最適な超平面の法線ベクトルは、以下のように表現できる。

$$\psi^0 = D \alpha^0 = \sum_{i=1}^m \alpha_i^0 y_i \mathbf{x}_i \quad (12)$$

ここで、 $\alpha^0$  は、 $m$  (データ数)-次元のベクトル。

しかし、ほとんどの制約が非アクティブであるから、 $\alpha^0$  のほとんどの要素は 0



$$(x_i * \psi) - b \geq 1, \quad \text{if } y_i = 1$$

$$(x_i * \psi) - b \leq -1, \quad \text{if } y_i = -1$$

$II$

$I$

$\psi$

★ ★ のデータが制約を満足するなら,  
 ● ● のデータは自動的に制約を満足する。

すなわち, ● ● に対する制約は 非アクティブ である。

$$\begin{aligned} \text{制約: } & x_i^T \psi - b \geq 1, & \text{if } y_i = 1, \\ & x_i^T \psi - b \leq -1, & \text{if } y_i = -1, \end{aligned}$$



# サポートベクトル

Kuhn-Tuckerの関係式により,

$$\alpha_i^0 (y_i (\mathbf{x}_i^T \boldsymbol{\psi}^0 - b^0) - 1) = 0$$

零でない  $\alpha_i^0$  に対応する  $i$  の集合を  $S$  とすると,

$$y_i (\mathbf{x}_i^T \boldsymbol{\psi}^0 - b^0) - 1 = 0, \quad \text{if } i \in S$$

$\mathbf{x}_i, i \in S$  をサポートベクトルと呼ぶ。



# サポートベクトル

最適超平面は, サポートベクトルだけで決めることができる。


$$\boldsymbol{\psi}^0 = \sum_{i \in S} \alpha_i^0 y_i \boldsymbol{x}_i \quad (13)$$

$$b^0 = \boldsymbol{x}_i^T \boldsymbol{\psi}^0 - y_i, \quad i \in S$$

$$f(\boldsymbol{x}) = \boldsymbol{\psi}^0 \boldsymbol{x} = \sum_{i \in S} (\alpha_i^0 y_i \boldsymbol{x}_i^T \boldsymbol{x}) = b^0 \quad (14)$$




# 線形分離不可能な場合



線形分離不可能  
= 与えられた複数のクラスのデータを  
分離する超平面が存在しない



# 線形分離不可能な場合




マージン 1 の超平面を考える。

$$\begin{aligned}\psi^T \cdot x_i - b &= 1, \\ \psi^T \cdot x_i - b &= -1,\end{aligned}$$





# 線形分離不可能な場合



以下のロス関数を定義する。

$$F(\xi) = \sum_{i=1}^m \xi_i, \quad \xi_i \geq 0. \quad i = 1, 2, \dots, m$$

$\xi_i$  は, マージン 1 の超平面から相手クラス側にはみ出した距離。

$$y_i(\psi^T x_i - b) \geq 1 - \xi_i,$$





# 線形分離不可能な場合

問題は,

$$\begin{aligned} \min & \left( \frac{1}{2} \boldsymbol{\psi}^T \boldsymbol{\psi} + C \cdot \sum_{i=1}^m \xi_i \right) \\ \text{s.t. } & y_i(\boldsymbol{\psi}^T \mathbf{x}_i - b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad i = 1, 2, \dots, m \end{aligned} \quad (14)$$

ラグランジュ関数は, 定数  $\alpha, \beta$  を用いて以下のようになる。

$$\begin{aligned} L(\boldsymbol{\psi}, \boldsymbol{\xi}, b, \boldsymbol{\alpha}, \boldsymbol{\beta}) = & \frac{1}{2} \boldsymbol{\psi}^T \boldsymbol{\psi} + C \cdot \sum_{i=1}^m \xi_i \\ & - \sum_{i=1}^m \alpha_i (y_i(\boldsymbol{\psi}^T \mathbf{x}_i - b) - 1 + \xi_i) - \sum_{i=1}^m \beta_i \xi_i \end{aligned} \quad (15)$$



# 線形分離不可能な場合

変形して,

$$L(\boldsymbol{\psi}, \boldsymbol{\xi}, b, \boldsymbol{\alpha}, \boldsymbol{\beta}) = \frac{1}{2} \boldsymbol{\psi}^T \boldsymbol{\psi} + C \cdot \|\boldsymbol{\xi}\|_1 - \boldsymbol{\alpha}^T D \boldsymbol{\psi} + b \boldsymbol{\alpha}^T \mathbf{y} + \|\boldsymbol{\alpha}\|_1 - \boldsymbol{\alpha}^T \boldsymbol{\xi} - \boldsymbol{\beta}^T \boldsymbol{\xi} \quad (15')$$


双対問題は,

$$\alpha^0 = \max_{\boldsymbol{\alpha}} L(\boldsymbol{\alpha}) = \max_{\boldsymbol{\alpha}} \left( -\frac{1}{2} \boldsymbol{\alpha}^T A \boldsymbol{\alpha} + \|\boldsymbol{\alpha}\|_1 \right) \quad (16)$$
$$A = (y_i y_j \mathbf{x}_i^T \mathbf{x}_j)$$

s.t.


$$0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, m \quad (17)$$





# 次元拡張

- 線形識別不可能なデータも，次元を拡張すると線形識別可能になることがある。



- カーネルトリック：ラグランジュ関数の中の  $x_i^T x_j$  を  $K(x_i, x_j)$  で置き換える。 $x_i$  を高次元のベクトル  $\phi(x_i)$  に写像してマージン最大化するのと同じ効果を持つ。



# まとめ

- マージンを最大化する基準で識別境界を決める手法をサポートベクタマシン (SVM) と呼ぶ。
- SVMの設計は、不等式制約の最適化問題を解くことで実現できる。



# 演習問題

1. SVMの説明にある, 式(14) を導け。
2. サポートベクタに対するラグランジュ係数を $\alpha^0$ , マージンを $\rho$ とすると,

$$\boldsymbol{\psi}^{0T} \boldsymbol{\psi}^0 = \sum_{i=1}^m \alpha_i^0$$

$$\rho(\boldsymbol{\psi}^0) = \frac{1}{\|\boldsymbol{\psi}^0\|}$$

$$L(\boldsymbol{\alpha}) < L(\boldsymbol{\alpha}^0) = \frac{1}{2} \frac{1}{\rho(\boldsymbol{\psi}^0)^2}, \quad \boldsymbol{\alpha} \neq \boldsymbol{\alpha}^0$$


を証明せよ。





# 演習問題

3. カテゴリAとして,  $(1,2), (0,1), (-1,2)$ が, カテゴリBとして,  $(0,-1), (-1,-2), (-2,0)$  が与えられたとき, これらのカテゴリをマージン最大化基準で分離する直線を求めよ。



# 演習問題

4. SVMの説明にある, 式(17) を導け。
5. クラス A のデータが,  $(1,2), (0,1), (-1,0), (-1,2)$ , クラス B のデータが  $(0,-1), (-1,-2), (-1,1), (-2,0)$  と与えられている。このとき, マージン最大化の基準で識別器を設計せよ。

